

# Tarea BDA03

Big Data Aplicado

---

**Alumno:** Darel Martínez Caballero

**Asignatura:** BDA

**Curso:** 2025/2026

---

# Índice

---

- 1. Objetivo del Documento
- 2. Desarrollo
  - 2.1. Preparación del Entorno
  - 2.2. Compañías con más retrasos (HQL)
  - 2.3. Compañías con mejor recuperación (HQL)
  - 2.4. Compañías con más retrasos (Pig Latin)
  - 2.5. Compañías con mejor recuperación (Pig Latin)
- 3. Conclusiones
- 4. Bibliografía

# 1. Objetivo del Documento

---

El presente documento tiene como objetivo presentar las soluciones razonadas a los ejercicios planteados en la Tarea Online BDA03. Se aborda el análisis de un dataset de vuelos en EE.UU. utilizando herramientas del ecosistema Hadoop, específicamente **Hive** para consultas SQL y **Pig Latin** para procesamiento de flujo de datos.

## 2. Desarrollo

---

### 2.1. Realiza el proceso de preparación que se hizo en la guía práctica

Para preparar el entorno y los datos, se realizaron los siguientes pasos secuenciales:

1. **Descarga y extracción de datos:** Se actualizó el sistema, se instaló `unzip` y se descomprimió el archivo `archive.zip` obteniendo `airports.csv` y `flights.csv`.
2. **Carga en HDFS:** Se creó el directorio `/user/root/flights` en el sistema de ficheros distribuido y se subieron ambos archivos CSV.
3. **Modelado en Hive:**
  - Se creó la base de datos `bda03`.
  - Se definieron las tablas externas `airports` y `flights`, especificando el formato delimitado por comas y saltando la cabecera.
4. **Carga de datos:** Se cargaron los datos desde HDFS a las tablas de Hive.

## 2.2. HQL: Las cinco compañías que más vuelos retrasados tienen

**Pregunta:** Con una consulta de HQL muestra las cinco compañías que más vuelos retrasados tienen (arrdelay > 15).

**Razonamiento:** Se seleccionan los vuelos donde el retraso en llegada (`arrdelay`) es mayor a 15 minutos. Luego, se agrupan por compañía (`carrier`) y se cuenta el número de incidencias. Finalmente, se ordena de forma descendente y se limita a 5 resultados.

**Resultado obtenido:**

| Carrier | Vuelos Retrasados |
|---------|-------------------|
| WN      | 127601            |
| AA      | 59842             |
| DL      | 57668             |
| UA      | 57367             |
| US      | 40943             |

## 2.3. HQL: Las 5 compañías con mejor recuperación de tiempo

**Pregunta:** Muestra las 5 compañías que han recuperado el tiempo (`arrdelay` <= 15) en un mayor porcentaje de vuelos que salieron retrasados (`depdelay` > 15).

**Razonamiento:** Primero filtramos los vuelos que salieron con retraso. De ese subconjunto, calculamos el porcentaje de recuperación dividiendo los casos exitosos (llegada a tiempo) entre el total de salidas atrasadas para esa compañía.

**Resultado obtenido:**

| Carrier | Porcentaje Recuperado |
|---------|-----------------------|
| UA      | 0.24507               |
| WN      | 0.23570               |
| FL      | 0.22657               |
| DL      | 0.21578               |
| AA      | 0.20162               |

## 2.4. Pig Latin: Las cinco compañías con más retrasos

**Ejercicio:** Resuelve el ejercicio 2 con Pig Latin.

**Desarrollo:** Se replicó la lógica de la consulta SQL utilizando transformaciones de Pig. Se cargaron los datos, se filtraron los retrasos, se aplicó `GROUP BY` y `FOREACH` para contar, y finalmente se ordenó y limitó el resultado.

**Resultado obtenido:**

| Carrier | delayed_flights |
|---------|-----------------|
| WN      | 127601          |
| AA      | 59842           |
| DL      | 57668           |
| UA      | 57367           |
| US      | 40943           |

## 2.5. Pig Latin: Mejores recuperaciones de tiempo

**Ejercicio:** Resuelve el ejercicio 3 con Pig Latin.

**Desarrollo:** Este script es más complejo ya que requiere calcular una tasa. Se filtran las salidas retrasadas, se genera una proyección con un flag binario (1 si recuperó, 0 si no) usando el operador ternario, y luego se agrupa para calcular la media (suma de recuperados / total).

**Resultado obtenido:**

| Carrier | percent_recovered   |
|---------|---------------------|
| UA      | 0.24507301133462678 |
| WN      | 0.23570878543927196 |
| FL      | 0.2265728843597696  |
| DL      | 0.21578780710414067 |
| AA      | 0.20162014676224854 |

### 3. Conclusiones

---

A través de esta práctica se ha podido comprobar la potencia y flexibilidad del ecosistema Hadoop para el procesamiento de grandes volúmenes de datos. Se evidencia cómo **Hive** facilita el acceso a los datos mediante un lenguaje familiar SQL, ideal para analistas y consultas estructuradas. Por otro lado, **Pig Latin** ofrece un enfoque procedural flujo de datos que permite un control más granular sobre las transformaciones paso a paso, siendo muy potente para pipelines de datos complejos. Ambos frameworks, aunque operan sobre la misma base (MapReduce/Tez y HDFS), ofrecen abstracciones complementarias para distintos perfiles y necesidades.

### 4. Bibliografía

---

- Material docente de la asignatura Big Data Aplicado (BDA03).
- Apache Hive Documentation. <https://hive.apache.org/>
- Apache Pig Documentation. <https://pig.apache.org/>
- StackOverflow & Kaggle Community Resouces.