

Casos Prácticos de Aprendizaje Automático con BigML - Guía

Introducción al Caso Práctico

Eva, recién graduada en Inteligencia Artificial, busca mejorar su currículum desarrollando modelos prácticos con **BigML**, una plataforma online con versión gratuita ideal para proyectos educativos. A lo largo de esta guía trabajaremos con tres algoritmos principales aplicados a una base de datos de vinos.

1. Árbol de Decisión - Aprendizaje Supervisado

Contexto del Problema

- **Dataset:** "Red Wine Quality" (1,599 instancias)
- **Objetivo:** Predecir la calidad del vino (campo objetivo)
- **Algoritmo:** Árbol de Decisión (ideal cuando no se conocen correlaciones previas)

Proceso Paso a Paso

A. Preparación de la Plataforma

1. **Registro en BigML:** Crear cuenta gratuita (hasta 16 MB de datos)
2. **Acceso a Datasets:** Usar datasets preexistentes de la comunidad
3. **Selección:** Buscar y "adquirir" el dataset "Red Wine Quality"

B. Análisis Exploratorio

- **Variables:** pH, sulfatos, acidez, ácido cítrico, azúcar residual, etc.

- **Tipos:** Mayoritariamente numéricas
- **Calidad:** Sin datos perdidos o erróneos
- **Herramientas:**
 - Histogramas de distribución
 - Scatterplots para relaciones entre variables
 - Posibilidad de editar/desactivar categorías irrelevantes

C. Partición de Datos (CRUCIAL)

- **80% para entrenamiento** (1,279 instancias)
- **20% para validación** (320 instancias)
- **Propósito:** Evaluar el modelo con datos no vistos durante el entrenamiento

D. Entrenamiento del Modelo

- Selección de "Model" (árbol de decisión en BigML)
- Entrenamiento rápido (segundos con este volumen de datos)
- **Visualizaciones disponibles:**
 - Representación gráfica del árbol
 - Niveles de confianza por rama
 - Distribución de predicciones
 - Importancia de variables (Split Field)

E. Evaluación y Validación

1. **Pruebas con nuevos datos:** - Introducción manual caso por caso - Por lotes usando el 20% reservado
2. **Métricas de evaluación:** - Comparación entre calidad real y predicha - Descarga de resultados en CSV - Análisis de confiabilidad y precisión

Punto Clave de Aprendizaje

La partición 80/20 permite **medir la capacidad de generalización** del modelo, evitando el sobreajuste (overfitting) y demostrando su utilidad con datos reales no vistos durante el entrenamiento.

2. Clustering - Aprendizaje No Supervisado

Contexto del Problema

- **Mismo Dataset:** "Red Wine Quality" (80% de los datos)
- **Objetivo:** Descubrir agrupaciones naturales sin variable objetivo
- **Comparación:** Contrastar resultados con el modelo supervisado anterior

Proceso Específico

1. **Selección del Dataset:** Usar el mismo 80% del ejercicio anterior
2. **Lanzamiento del Entrenamiento:** - Desde el menú **sin el rayo** (permite ajustar parámetros) - Configuración personalizada del algoritmo
3. **Análisis de Resultados:** Identificación de clusters naturales en los datos

Valor Añadido

El clustering puede revelar **patrones ocultos** en la composición de los vinos que complementen los hallazgos del árbol de decisión, ofreciendo una visión más completa de los datos.

Herramientas y Buenas Prácticas

Características de BigML

- **Interfaz intuitiva** con visualizaciones integradas
- **Preprocesamiento:** Detección de datos faltantes/erróneos
- **Múltiples formatos:** CSV, XLS, etc.
- **Tutoriales disponibles** en "Getting Started"

Recomendaciones para Estudiantes

1. **Explorar datasets comunitarios** antes de subir propios
2. **Documentar cada paso** para incluir en portafolio
3. **Probar diferentes algoritmos** con los mismos datos

4. **Analizar métricas** para entender limitaciones y fortalezas

Aplicación Práctica en Entrevistas

- **Demostrar proceso completo:** Desde preparación de datos hasta evaluación
- **Explicar decisiones técnicas:** Por qué árbol de decisión vs otros algoritmos
- **Mostrar capacidad crítica:** Análisis de resultados y posibles mejoras
- **Presentar casos contrastados:** Supervisado vs no supervisado

Conclusión

Este ejercicio guiado proporciona **experiencia práctica real** con herramientas profesionales, desarrollando habilidades directamente aplicables en el mercado laboral de IA. La metodología 80/20, el uso de múltiples algoritmos y el análisis comparativo constituyen un **caso de estudio completo** que demuestra competencia técnica y pensamiento analítico.

Ejemplo de aplicación: En una entrevista, Eva podría mostrar cómo un mismo dataset puede abordarse desde perspectivas complementarias (supervisado y no supervisado), obteniendo insights diferentes pero igualmente valiosos para la toma de decisiones en la industria vitivinícola.

Ejercicio Práctico de Clustering y Redes Neuronales en BigML - Guía

Parte 1: Clustering con el Dataset de Vinos

Configuración y Entrenamiento del Modelo

- **Elección del algoritmo:** Se puede seleccionar entre **K-Means** (número de clusters definido por el usuario) o **G-Means** (el algoritmo determina el número óptimo).

- **Ejemplo práctico:** Se utiliza **K-Means con K=8** para agrupar vinos según sus características químicas.

Interpretación del Modelo Entrenado

- **Visualización:** BigML representa los clusters como círculos de tamaño proporcional al número de instancias que contienen.
- **Centroides:** Cada cluster tiene un centroide que representa los valores promedio de sus características.
- Ejemplo: En el cluster 7, el centroide muestra:
 - Acidez fija: 7.97
 - Acidez volátil: 0.57
 - 266 instancias pertenecen a este grupo.
- **Análisis por cluster:** Se puede generar un **modelo predictivo específico** para cada cluster, lo que permite identificar patrones y relaciones entre variables (ej. composición química y calidad del vino).

Predicción y Aplicación Práctica

- **Batch Centroid:** Se utiliza para predecir a qué cluster pertenece cada vino del conjunto de prueba (20% de los datos reservados).
- **Aplicación en enología:**
 - Identificar el cluster con mayor valor en "Calidad".
 - Analizar los parámetros de ese cluster para replicar condiciones en el cultivo (ej. ajustar acidez, azúcares) con ayuda de un técnico agrícola.

Parte 2: Redes Neuronales con Datos de League of Legends

Preparación de Datos en BigML

1. **Carga del dataset:** - Subir el archivo `Base de datos - League of Legends.csv` (9.29 MB) en **Sources**. - Límite de la cuenta gratuita: archivos ≤ 16 MB.

2. **Creación del dataset:** - BigML convierte el CSV a su formato interno. -
Revisión crítica: Desactivar campos irrelevantes (ej. ID de usuario) para optimizar el entrenamiento.
3. **Definición del objetivo:** Establecer la columna "**winner**" (equipo 1 o 2) como variable a predecir.

Entrenamiento y Análisis del Modelo

- **Algoritmo: DEEPNET** (red neuronal profunda de BigML).
- **Resultados gráficos:**
 - Visualización de probabilidades de victoria (azul = equipo 1, verde = equipo 2).
 - Ejemplo: Gráfico de "torres destruidas" muestra que el equipo 1 tiene mayor probabilidad de ganar incluso con menos torres destruidas, lo que sugiere posibles sesgos en los datos o factores no considerados.
- **Interpretación:**
 - La frontera entre colores no inicia en (0,0), indicando desequilibrios.
 - Necesidad de investigar: ¿sesgo en el juego, datos insuficientes o variables omitidas?

Predicción y Evaluación

- **Prueba del modelo:** Introducir valores manuales para predecir al ganador (ej. resultado "1.12" indica mayor probabilidad para el equipo 1).
- **Evaluación de eficacia:**
 - **Error común:** No dividir inicialmente los datos en entrenamiento (80%) y prueba (20%).
 - **Solución:** Volver al dataset, hacer la partición y reentrenar el modelo para una evaluación válida.

Puntos Clave para el Estudio

1. **Clustering:** - Centroides resumen las características de cada grupo. - Útil para segmentación y análisis detallado por categorías.
2. **Redes Neuronales:** - La calidad de los datos es crucial (limpieza, selección de variables). - La interpretación visual ayuda a detectar anomalías o sesgos.

3. **BigML:** - Interfaz intuitiva para entrenar, predecir y evaluar modelos. - Siempre reservar parte de los datos para validación.
-

Autoevaluación y Consejos

- **Pregunta:** ¿Es posible usar G-Means en lugar de K-Means en el ejercicio de vinos? **Respuesta:** Sí, G-Means determina automáticamente el número de clusters.
 - **Revisión de datos:**
 - **Verdadero:** Limpiar y "aligerar" los datasets antes del entrenamiento es esencial para mejorar la eficiencia y precisión del modelo.
 - **Recomendación:** En problemas específicos (ej. videojuegos), conocer el dominio mejora la interpretación de resultados.
-

Resumen ejecutivo (≈100 palabras): Esta guía cubre dos ejercicios prácticos en BigML: clustering con datos de vinos y redes neuronales aplicadas a League of Legends. En el primero, se utiliza K-Means para agrupar vinos, analizando centroides y generando modelos predictivos por cluster. En el segundo, se entrena una red neuronal (DEEPNET) para predecir el ganador, destacando la importancia de la preparación de datos y la detección de sesgos. Ambos casos enfatizan la configuración, interpretación visual y aplicación práctica de los modelos, con recomendaciones para optimizar el proceso en BigML.